

G4 Lead Scorer — Challenge 003

Chat Export: Sessao de planejamento, analise e arquitetura

Guilherme Pardin

7 de julho de 2026

Ferramentas: Claude Opus 4.6 (claude.ai) + Claude Code (Opus 4.7)

Este documento registra o processo completo de trabalho entre Guilherme Pardin e o Claude na sessao de planejamento, analise de dados, definicao do modelo de scoring, arquitetura do CRM, e preparacao da submissao para o desafio AI Master do G4 Educacao.

Fase 1 — Analise dos challenges e escolha estrategica

Guilherme apresentou os 4 challenges disponiveis (Churn, Suporte, Lead Scorer, Social Media). O Claude analisou cada um e recomendou o Challenge 003 (Lead Scorer) com base no perfil profissional de Guilherme — que opera dois CRMs em producao (Nutriceler e Grupo Tala) para clientes B2B no agronegocio. A justificativa: o entregavel e software funcional (nao documento), o stack encaixa (Next.js + Supabase), e a experiencia com pipeline de vendas e real.

Fase 2 — Diagnostico da submissao anterior

Guilherme havia submetido uma versao anterior do challenge que nao foi aprovada. O Claude clonou o repositorio, analisou o codigo (scoring.py, app.py, ai_insights.py), e examinou screenshots da aplicacao Streamlit. Diagnostico:

- 1. Streamlit parecia prototipo tecnico, nao ferramenta de vendas
- 2. Features de IA exigiam API key do avaliador — metade do app nao funcionava
- 3. Over-engineering nas partes erradas (multi-provider com MD5 cache)
- 4. Interface mostrava dados em vez de ajudar a decidir
- 5. Process log parecia portfolio de prompt engineering, nao raciocinio real
- 6. Faltava a visao de CRM que Guilherme ja sabe construir

Fase 3 — Exploracao profunda dos dados

O Claude analisou os 4 CSVs cruzados (8.800 registros no pipeline, 85 contas, 7 produtos, 35 vendedores). Principais descobertas:

Descoberta-chave: A combinacao vendedor+setor tem variacao de ate 54 pontos percentuais em taxa de conversao. Markita Hansen converte 90.5% em entretenimento e 35.7% em tecnologia. Boris Faz converte 81% em software e 35% em financeiro.

Essa descoberta definiu a tese central do produto: organizar o time por especializacao setorial e a maior alavanca de desempenho disponivel.

Dimensao	Win Rate Range	Impacto
Vendedor x Setor	Ate 54pp de variacao	MAIS FORTE
Vendedor x Produto	Ate 65pp de variacao	Forte
Produto geral	60% - 65%	Moderado
Setor geral	61% - 65%	Moderado
Sazonalidade (mes)	55% - 80%	Fraco

Fase 4 — Referencia de produto real (Nutriceler + Grupo Tala)

Guilherme compartilhou screenshots e código-fonte dos CRMs Nutriceler e Grupo Tala. O Claude analisou os padrões de UX já validados com vendedores reais:

- Kanban com cards mostrando nome, telefone, localização, vendedor, valores
- Página de tarefas agrupada por tipo de ação com badges de urgência
- Dashboard gerencial com KPIs, ranking de vendedores, filtros por período
- Hierarquia Gestor > Coordenador > Vendedor com isolamento de dados
- Drawer lateral de detalhes do lead com abas Informações/Histórico

Esses padrões foram adaptados para o challenge do G4.

Fase 5 — Modelo de scoring (6 dimensões)

Modelo de scoring composto, 0-100 pontos:

Dimensão	Peso	Lógica
Estágio da negociação	0-25 pts	Em negociação = 25, Prospeção = 10
Afinidade vendedor+contexto	0-25 pts	Cascade: vendedor x setor > vendedor x produto > vendedor
Valor da negociação	0-20 pts	Proporcional ao teto do produto
Conversão do produto	0-15 pts	Taxa histórica por linha
Qualidade da empresa	0-10 pts	Revenue + employees + conta conhecida
Sazonalidade	0-5 pts	Taxa de conversão por mês de entrada

Erro corrigido: A distribuição inicial ficou com 77% dos deals como 'morno'. Guilherme decidiu usar percentis (P85/P50/P15) em vez de thresholds fixos, gerando distribuição de 15/37/33/15% (Quente/Morno/Frio/Em Risco).

Outro ajuste: Sazonalidade tinha peso 20 na versão anterior — mesmo que o valor da negociação. Foi reduzida para 5 após análise do spread real (25pp vs 54pp do fit vendedor+setor).

Fase 6 — Decisões de produto (humanas)

Decisões que vieram do Guilherme, não da IA:

Hierarquia de 3 níveis: Gestor (Head de RevOps) vê tudo, Gerente vê só seu time, Vendedor vê só seus dados. Isolamento completo por perfil.

Remanejamento automático: Em vez de sugerir realocação, o sistema já classifica. Na prática, sugestão não gera ação.

Cadência por temperatura: Quentes = contato diário. Mornos = follow-up a cada 2-3 dias. Frios = email semanal ou descartar.

Naming honesto: O scoring é algorítmico, não IA. A página se chama 'Priorização', não 'Análise IA'.

Foco em pessoas: Cada nível vê as pessoas do nível abaixo que precisam de atenção. Head vê gerentes com problema. Gerente vê vendedores desalinhados. Vendedor vê negociações prioritárias.

Organizacao da informacao em 3 camadas: Foco agora > Recomendacoes > Dados de suporte (colapsaveis).

Fase 7 — Construcao com Claude Code

Guilherme compilou todas as decisoes, dados e padroes de UI num documento CLAUDE.md de ~300 linhas. Esse prompt foi usado como input para o Claude Code (Opus 4.7) construir o app Next.js completo.

Durante o build, foram feitas multiplas iteracoes via prompts adicionais:

- Ajuste de hierarquia de perfis (3 niveis)
- Traducao completa para portugues
- Correcao de performance (remover animacoes que travavam)
- Restauracao de shadows sem impacto em performance
- Sidebar retratil (expandida/colapsada)
- Simplificacao do dashboard (3 camadas)
- Score visivel nos cards do pipeline
- Integracao do logo G4 com paleta navy+dourado
- Narrativa de especializacao setorial como fio condutor

Fase 8 — Documentacao e submissao

Guilherme gravou um relato em audio do processo, que foi transcrito e formatado como process log. O relato destaca as decisoes humanas vs contribuicoes da IA, mantendo a voz autentica.

Submissao: Fork do repositorio G4, branch submission/guilherme-pardin, PR para main com codigo, README, process log, screenshots, e deploy na Vercel.

Resumo do processo

Duracao total da sessao: ~6 horas

Mensagens trocadas: ~60+

Ferramentas: Claude Opus 4.6 (planejamento) + Claude Code Opus 4.7 (construcao)

Iteracoes de UI no Claude Code: 10+

Decisoes humanas documentadas: 8 decisoes-chave de produto

Erros da IA corrigidos: 3 (distribuicao concentrada, sazonalidade inflada, dashboard poluido)