

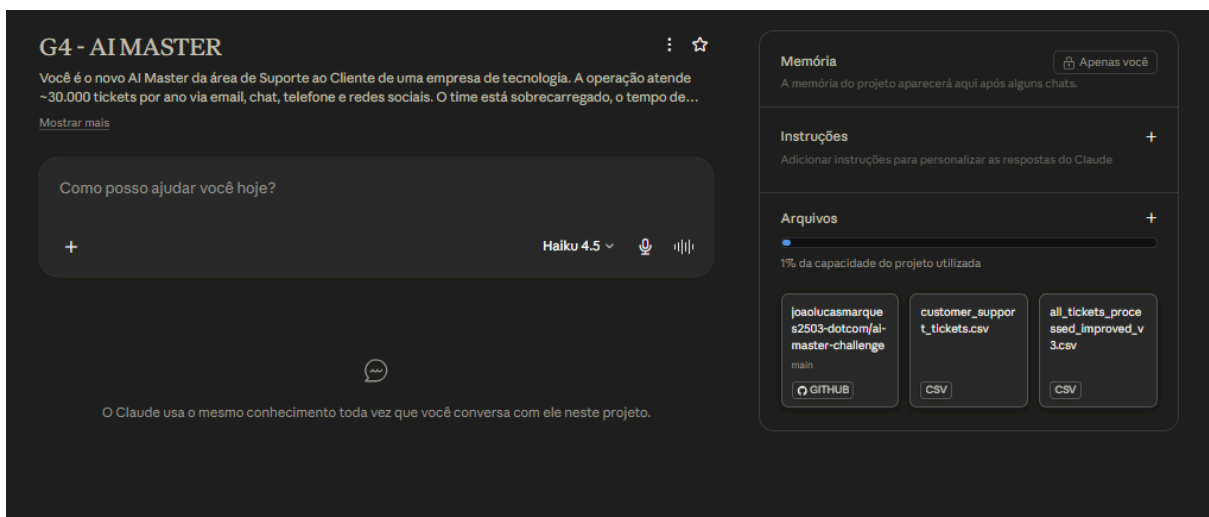


REGISTRO DE ATIVIDADES

Primeiro passo foi fazer o FORK do projeto dentro do meu repositório



Em seguida criei um projeto dentro do Claude “G4 - AI MASTER” e Seleccionei todo o repositório incluindo apenas o “Challenge 002”



O próximo foi criar um conjunto de instruções, para que o Claude (onde eu vou utilizar como principal ferramenta de IA, tenha total contexto do que será desenvolvido.

Em seguida, eu pedi para o Claude ler todos os arquivos do projeto.

O objetivo nesse momento é ter total contexto do que está acontecendo / problema atual

Em paralelo será utilizado o Chat Gpt como uma técnica de META PROMPT (utilizar a própria IA para criar os melhores prompt) o motivo dessa escolha é ter mais controle do resultado esperado e também não sobrecarregar a mesma IA para todo o projeto, isso pode gerar custos desnecessários.

Informação importante

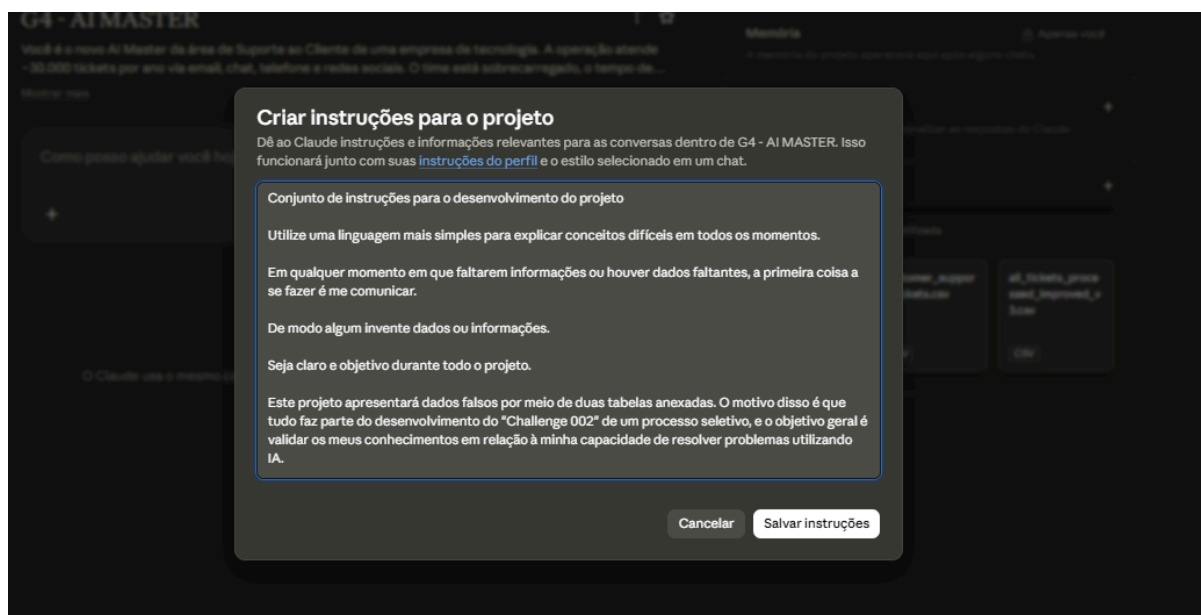
Será utilizado como modelo principal: FABLE 5 e OPUS 4.8 para:

Para prompts e perguntas / problemas isolados será utilizado : Chat GPT FREE

Obs: O chat gpt será utilizado para funções muito específicas, não sendo necessário ter maior contexto sobre o projeto.

Ex: prompt específico, dúvida sobre o projeto / termos muito específicos / condições.

CRIANDO CONJUNTO DE INSTRUÇÕES



1ª ETAPA - LEITURA, COMPREENSÃO E CONTEXTO

Nessa etapa do projeto o objetivo é garantir que o Claude tenha total contexto sobre o projeto

Obs: Sempre garantindo clareza de tudo que está sendo feito

G4 - AI MASTER / Análise e automação inteligente de tickets com NLP

Compartilhar

Nessa primeira etapa eu preciso que voce faça duas leituras

Primeira -> O projeto como um todo, requisitos, dicas, entregáveis, mapeamento, qual é o contexto geral do projeto

Segundo -> O challenge 002 como um todo, requisitos, dicas, entregáveis, mapeamento, qual é o contexto geral do projeto

Na primeira leitura eu espero que voce saiba o que está acontecendo e me escreva um texto contando tudo que voce entendeu

Na segunda leitura eu espero que voce estruture o problema com o máximo de informações possíveis e depois estruture a forma como vamos resolver isso

Lembrando que eu não quero que voce faça nada sozinho, vamos por etapas

1º Leitura e compreensão

2º Classifique em categorias (8 categorias) utilizando embedding + classificação zero-shot -> ESSA CLASSIFICAÇÃO IRA PERMITER ANALISAR DE FORMA MAIS PROFUNDA TODOS OS DADOS, GARANTINDO MAIS PRECISÃO

3º Criar um diagnóstico operacional

- Com base no Dataset 1, identifique-se com dados:
- 1. Onde o fluxo trava? Gargalos por canal, prioridade, tipo de ingresso. Quais combinações geram os piores tempos de resolução?
- 2. O que impacta a satisfação? Quais variáveis mais influenciam o Customer Satisfaction Rating? É o tempo de resposta? O canal? O tipo de problema?
- 3. Quanto estamos perdendo? Quantifique em horas e, se possível, estime personalizado. Onde está o maior desperdício recuperável?

Criar uma proposta de automação

Com base em ambos os conjuntos de dados, proponha:

- O que automatizar — Classificação automática, roteamento inteligente, respostas sugeridas, rastreamento de prioridade, detecção de duplicatas — o que faz sentido com base nos dados.
- O que NÃO automatizar — Nem tudo deve ser delegado para IA. Quais tipos de ticket desativar julgamento humano? Justifique com exemplos dos dados.
- Como funcionaria na prática — Descreva o fluxo proposto: ticket entra → o que acontece em cada etapa → onde IA atua → onde humano intervém.

Nessa etapa o objetivo é ilustrar o fluxo atual (destacando o problema) e em seguida criar uma automação que resolva esse problema com base em tudo que foi analisado

(Na parte de criar uma solução, o objetivo é criar algo fora do comum, criar algo novo, que seja eficiente, rapido e funcional, mas que seja diferente do convencional, viabilizando (a resolução do problema) não apenas resolver o problema mas também, inovar

Pense da seguinte forma: Foi pedido que o AI MASTER resolvesse um determinado problema, mas se: nós desenvolvessemos algo que alem de resolver o problema atual pudesse trazer recursos novos que garantem que a empresa que nós estamos atuando pudesse se destacar (foco em inovação)

DICA PARA AS DUAS BASE DE DADOS:

- O Dataset 1 tem estatísticas operacionais. O Dataset 2 tem 48K textos classificados em 8 categorias — excelente pra treinar/testar classificados.
- Usar NLP para classificar tickets" é genérico. "Classificar ingressos em 8 categorias com 92% de acurácia usando embeddings + classificação zero-shot" é específico.

Nesse prompt inicial o objetivo foi: garantir que o Claude faça toda a leitura do projeto e com base em tudo que já estava escrito no repositório do GITHUB eu estruture todo o projeto em etapas, inclusive o prompt ficou tao bem detalhado que eu incluí nas instruções do projeto (esse prompt)

Nessa primeira etapa o Claude atendeu com excelência o que eu pedi e conseguiu identificar uma vulnerabilidade / pegadinha. Mas o que importa é: temos tudo estruturado e já podemos avançar.

Análise feita

Em um texto de 10 linhas me conte o que voce identificou em relação a vulnerabilidade / pegadinha

 **Vulnerabilidades/Pegadinhas Identificadas (10 linhas)**

Os dados são **100% sintéticos**: resoluções aleatórias, templates repetidos, balanceamento perfeito demais, e 67% dos tickets sem dados de conclusão. A pegadinha principal é que **só 2.769 de 8.469 tickets têm história completa** (satisfação + tempo de resolução), reduzindo drasticamente a base útil para diagnóstico. Tempos de resolução **impossíveis** (anterior à primeira resposta) exigem limpeza. O Dataset 2 tem textos super processados/tokenizados, prejudicando qualidade do classificador. A armadilha estratégica: **parecer que resolveu o problema com dados fake** é fácil — o diferencial é documentar as decisões tomadas, filtros aplicados, e mostrar no process log onde você corrigiu/descartou dados ruins. Eles querem ver **juízo**, não apenas "resultado bonito com dados ruins".

CHAT COM O CLAUDE

<https://claude.ai/share/3ba6a748-0513-4549-8d77-a71c753c91a0>

IMPORTANTE

Todo o desenvolvimento do projeto será dividido em chats diferentes dentro do Claude, portanto como será muito textos (prompts) para não sobrecarregar o documento e dificultar a leitura, eu vou anexar o link de cada histórico de prompts e conversas com o Claude, mas toda a lógica será escutar por aqui.

2ª ETAPA - CLASSIFICAÇÃO E ANÁLISE

Nessa etapa nós vamos classificar tudo em 8 categorias descritas no projeto (repositório) por meio de **embedding + classificação zero-shot**

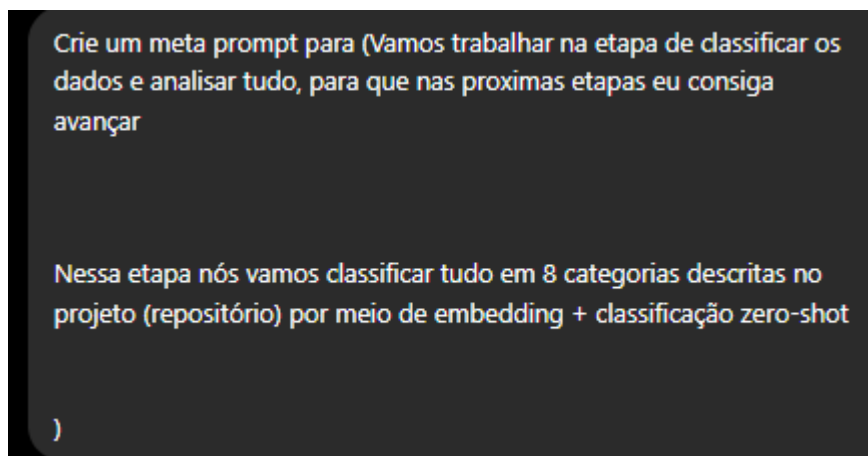
Esse tipo de classificação permite exatamente isso: que os seus dados se tornem profundamente organizados, estruturados e segmentados. Além de organizar e segmentar, essa técnica resolve problemas que os métodos tradicionais não conseguem.

Embedding: Um modelo de Inteligência Artificial lê as duas tabelas e converte todos os textos em sequências numéricas (vetores) que capturam o **significado semântico**.

Classificação Zero-Shot (Similaridade): O algoritmo calcula a distância matemática (como a *cosine similarity*) entre o vetor do dado da Tabela 1 e os vetores das categorias da Tabela 2. O rótulo com a maior similaridade é atribuído ao dado.

Referências: [Cloudflare link](#)

Nessa etapa foi preciso aperfeiçoar o prompt por meio da técnica utilizada “Meta Prompt” Utilizar a IA para criar o próprio prompt, não exigindo contexto total sobre o projeto, pois o objetivo do Chat GPT é trabalhar de forma isolada



O prompt gerado pelo Chat GPT ficou extremamente grande e por isso será possível ver o que foi criado por meio do link do chat com o Claude

CHAT COM O CLAUDE

<https://claude.ai/share/e72b87fe-7fa7-4a8f-a1cc-910cf2229188>

Cruzamento dos datasets — aplicando o classificador do Dataset 2 nos tickets do Dataset 1

Após o cruzamento de dados o resultado foi:

Experimento executado: o classificador treinado em 47.837 tickets de TI foi aplicado aos 8.469 tickets de consumo. Objetivo: testar se o conhecimento transfere entre domínios. **Resultado: não transfere — e isso foi provado com quatro testes independentes.**

Forçar o cruzamento (ex.: parear cada ticket com o "mais parecido" da outra base via embedding) geraria números bonitos em cima de uma relação inventada — exatamente o "feeling disfarçado de métrica" que você pediu para evitar.

O que ficou no lugar: análise complementar. O Dataset 2 serve para **provar a viabilidade técnica** da automação (acurácia por categoria, limiar de confiança que separa automático de humano). O Dataset 1 serve para o **diagnóstico operacional** (gargalos, satisfação, desperdício). Cada um responde o que só ele pode responder.

PARA NÃO TÉCNICOS (ENTENDER O QUE FOI FEITO)

O que foi feito

Quatro trabalhos, em sequência.

Primeiro, uma auditoria dos dados. Antes de analisar qualquer coisa, verifiquei se os dados eram confiáveis. Descobri que o Dataset 1 (8.469 tickets de consumo) é gerado artificialmente: os tempos são impossíveis, as notas de satisfação são sorteadas e as colunas não têm relação entre si.

Segundo, um classificador de tickets. Usando o Dataset 2 (47.837 tickets de TI já categorizados), construí um modelo que lê o texto de um chamado e diz a que categoria ele pertence, com 84,1% de acerto.

Terceiro, o diagnóstico e a proposta de automação. Respondi 5 das 6 perguntas do desafio com números, e declarei a sexta (custo em horas) como impossível de responder com esses dados.

Quarto, duas revisões críticas. Uma revisão forense que questionou minhas próprias conclusões, e o teste de aplicar o classificador nos tickets de consumo.

Como foi feito

A auditoria usou estatística formal. Testes de qui-quadrado e ANOVA verificam se duas variáveis têm relação real ou se a aparente relação é coincidência. Testei 21 combinações de colunas — nenhuma passou. Também comparei datas: todas as respostas caem numa janela de 27 horas, para compras espalhadas por dois anos.

O classificador foi construído em quatro tentativas, cada uma corrigindo a falha da anterior:

1. Descrevi as 8 categorias com minhas próprias palavras e deixei o modelo comparar — 24,4%.
2. Reescrevi as descrições usando o vocabulário que realmente aparece nos tickets — 37,5%.
3. Usei exemplos reais de cada categoria como referência — 72,0%.
4. Treinei um modelo para aprender as fronteiras entre as categorias — 84,1%.

A técnica por trás é o *embedding*: cada texto vira uma lista de números que representa seu significado, e textos com sentido parecido ficam próximos nesse espaço numérico. Isso permite comparar significado, não apenas palavras iguais.

A medição sempre separou os dados em duas partes: uma para o modelo aprender, outra para testar. O modelo só é avaliado em tickets que nunca viu — senão o resultado seria inflado.

O cruzamento aplicou o modelo treinado em TI aos tickets de consumo, e depois testou se as previsões faziam sentido: comparei a confiança entre os dois contextos, classifiquei os mesmos tickets com e sem o texto de preenchimento, e verifiquei se a categoria prevista tinha relação com as métricas reais.

Por que foi feito

A auditoria veio primeiro porque análise construída sobre dado ruim produz conclusão errada com aparência de rigor. Se eu tivesse pulado essa etapa, teria entregue um gráfico de "satisfação por canal" e uma estimativa de custo em reais — números corretos na aritmética e falsos na realidade.

O classificador foi construído porque as perguntas sobre automação exigem saber o que a máquina consegue categorizar sozinha. Sem medir, "usar IA para classificar tickets" é uma frase vazia. Com medição, vira uma regra operacional: 90,2% dos tickets podem ser roteados automaticamente com 88,6% de acerto; 1,8% precisam de pessoa, porque ali o acerto cai para 33%.

As quatro tentativas existiram porque a primeira falhou. O valor não está no número final, mas em ter identificado por que cada versão errava e corrigido —

vocabulário desalinhado, depois falta de exemplos, depois ausência de aprendizado supervisionado.

A revisão crítica foi feita porque a conclusão não verificada é suposição. Ela contradisse uma proposta minha anterior: eu havia sugerido "respostas sugeridas com base em resoluções passadas", até ler a coluna de resoluções e descobrir que são frases sem sentido.

O cruzamento foi feito porque a hipótese precisava ser testada, não presumida. O resultado foi negativo — o modelo não funciona fora do domínio em que aprendeu — mas produziu a regra mais importante da proposta: a métrica de confiança só é válida dentro do contexto em que foi validada. Fora dele, o sistema erra com confiança alta, sem sinalizar o erro

AVALIANDO TUDO QUE A IA FEZ ATÉ O MOMENTO

Nessa etapa eu irei questionar: como se eu fosse uma pessoa que não entende, em seguida irei fazer perguntas com o objetivo de entender em qual etapa estamos e para onde podemos avançar, aqui a ideia é avaliar todo o conteúdo gerado e não apenas aceitar e prosseguir. Todo desenvolvimento por meio de IA / Vibe Coding deve ser:

Entender / contextualizar -> Planejar -> Promptar -> mandar p/ IA -> executar-> avaliar -> corrigir -> testar -> avaliar -> avançar.

E sempre que travar em alguma parte o objetivo é (avaliar -> corrigir -> testar -> avaliar -> avançar)

Isso é o que eu acredito ser a melhor forma de trabalhar, mas não define o único formato.

Todos os testes podem ser visualizados por meio do link de classificação e análise, que foi o último link postado nesse documento até o momento.

CHAT COM O CLAUDE

<https://claude.ai/share/e72b87fe-7fa7-4a8f-a1cc-910cf2229188>

(mesmo link anexado da última vez)

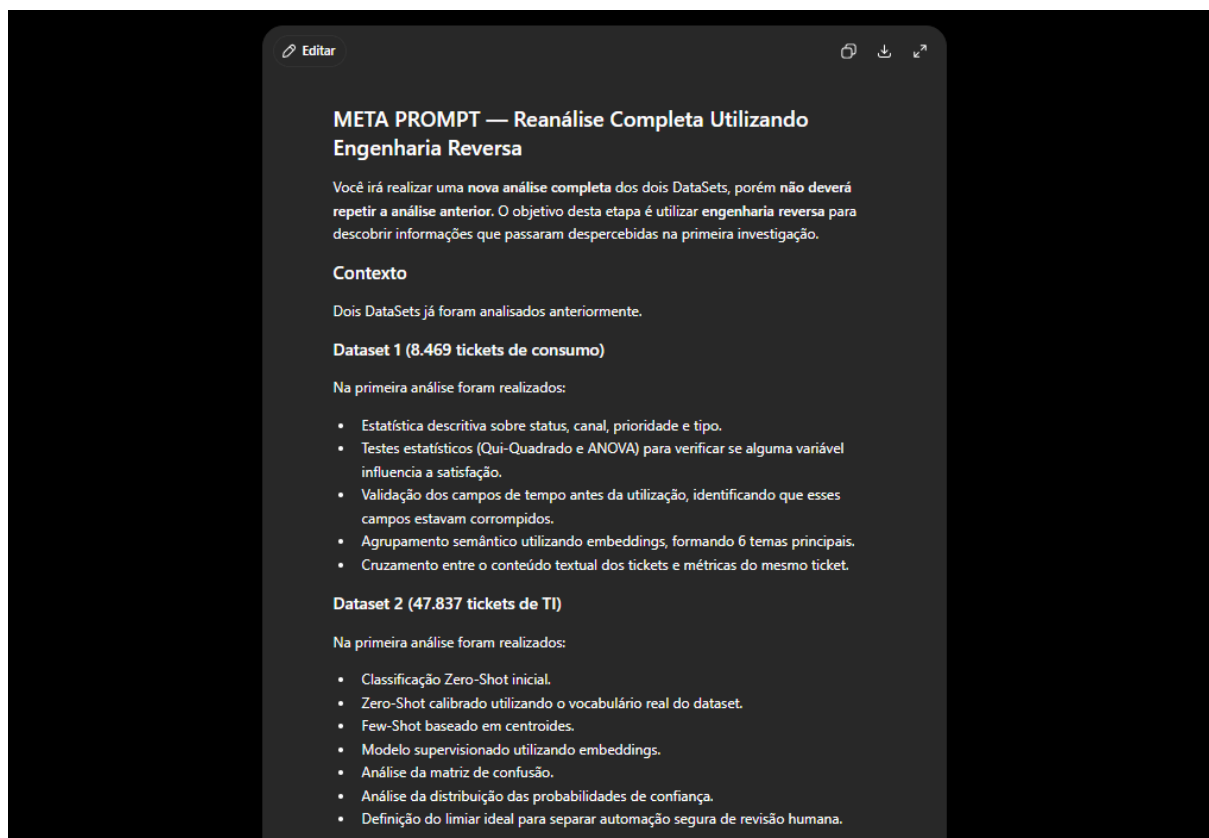
A próxima etapa deve ser avaliar os resultados, por isso irei usar o melhor modelo FABLE 5 para pode fazer essa avaliação

Mas antes disso vou criar um META prompt no Chat GPT para que possamos extrair o melhor resultado do FABLE 5

Por isso: no Claude eu pedi para ele me dar um leve contexto para que eu pudesse direcionar melhor o PROMPT criado pelo Chat Gpt

(Obs: No início do documento eu tinha escrito que, para perguntas / prompts isolados feito no Chat GPT, não precisaram de contexto, mas a ideia é ser tão específico na pergunta que não tem como ter erros e alucinação, outro ponto que eu analiso é: o modelo responsável por processar / interpretar essa resposta é o Claude Fable 5, logo a ideia é apenas criar um prompt sem precisar de uma resposta muito desenvolvida feita pelo Chat GPT, justamente pela função do modelo principal que é o Claude.

Prompt feito pelo Chat Gpt



Principais conclusões encontradas anteriormente

- 67,3% dos tickets nunca são resolvidos.
- Nenhuma variável apresentou impacto estatisticamente significativo na satisfação ($p > 0,25$), indicando forte evidência de dados sintéticos.
- 90,2% dos tickets podem ser classificados automaticamente com aproximadamente 88,6% de acerto.

Sua missão

Ignore completamente as conclusões anteriores durante a investigação.

Considere apenas que elas existem como referência histórica.

Faça uma nova análise partindo do princípio de que **ainda existem padrões ocultos que ninguém encontrou**.

Seu objetivo é aplicar **engenharia reversa**, questionando tudo que foi concluído anteriormente.

Em nenhum momento assuma que os resultados anteriores estão corretos apenas porque já foram obtidos.

Sempre tente responder:

- O que ninguém percebeu?
- Existe alguma relação escondida?
- Existe alguma inconsistência que passou despercebida?
- Existe algum padrão secundário que muda completamente a interpretação dos dados?
- Existe alguma evidência que contradiz as conclusões anteriores?
- Existem variáveis que parecem independentes isoladamente, mas se tornam relevantes quando analisadas em conjunto?
- Existem segmentos específicos onde os resultados mudam completamente?
- Há outliers ou grupos anômalos ignorados na primeira análise?
- Existem padrões temporais, semânticos, comportamentais ou estruturais que ainda não foram explorados?

Abordagem obrigatória

Você deverá agir como um investigador forense de dados.

Não aceite nenhuma conclusão sem validá-la novamente.

Sempre faça perguntas como:

- "E se a hipótese anterior estiver errada?"
- "Existe outra explicação possível?"
- "O que os dados estão escondendo?"
- "Qual informação parece irrelevante, mas pode ser extremamente importante?"
- "Existe alguma evidência indireta?"

Sempre procure relações não óbvias.

Não limite sua análise apenas às colunas.

Explore também:

- distribuição dos textos;
- padrões semânticos;
- correlação indireta;
- agrupamentos naturais;
- inconsistências estatísticas;
- padrões raros;
- exceções;
- comportamento dos extremos;
- diferenças entre pequenos grupos;
- possíveis erros de geração dos dados;
- sinais de enviesamento.

Engenharia reversa obrigatória

Durante toda a análise, tente descobrir:

- conclusões que poderiam ter sido diferentes;
- hipóteses que nunca foram testadas;
- cruzamentos que ninguém faria naturalmente;
- relações entre variáveis aparentemente desconectadas;
- informações escondidas dentro dos textos;
- padrões que aparecem apenas quando vários fatores são combinados simultaneamente.

Ao encontrar um padrão

Para cada descoberta, responda obrigatoriamente:

1. O que foi encontrado?
2. Por que isso passou despercebido anteriormente?
3. Qual evidência suporta essa conclusão?
4. Quão forte é essa evidência?
5. Isso altera alguma conclusão anterior?
6. Qual impacto essa descoberta teria no projeto?

Regras obrigatórias

- Não invente nenhuma informação.
- Nunca tire conclusões sem evidências presentes nos DataSets.
- Caso alguma hipótese não possa ser comprovada, informe explicitamente que ela permanece apenas como hipótese.
- Diferencie claramente fatos, evidências, hipóteses e interpretações.
- Sempre justifique todas as afirmações utilizando os próprios dados.
- Sempre explique o raciocínio utilizado para chegar a cada descoberta.
- Se identificar limitações nos dados, documente-as antes de prosseguir.

Objetivo final

Ao final da investigação, produza um relatório contendo:

- Todas as novas descobertas encontradas.
- Quais análises da primeira investigação foram confirmadas.
- Quais análises foram enfraquecidas ou contraditas.
- Quais novas hipóteses surgiram.
- Quais pontos passaram despercebidos na primeira análise.
- Quais cruzamentos revelaram os insights mais relevantes.
- Quais descobertas possuem maior potencial para impactar as próximas etapas do projeto.

O objetivo desta etapa não é repetir a análise anterior, mas realizar uma investigação aprofundada utilizando engenharia reversa para revelar padrões ocultos, inconsistências e oportunidades que ainda não foram identificados.

Após ter feito a revisão da análise feita foi possível perceber o que:

O Dataset 1 apresenta problemas estruturais que comprometem sua confiabilidade. Por causa dessas inconsistências, os dados não representam uma operação real e, portanto, não permitem a extração de métricas ou conclusões confiáveis. Qualquer análise baseada nesse conjunto de dados deve ser interpretada com cautela, pois os resultados podem refletir apenas a forma como os dados foram gerados, e não o comportamento de um ambiente real.

- **Dataset 1:** é essencialmente um conjunto de dados sintéticos (artificiais) e não representa uma operação real de suporte; seu principal valor é mostrar que você soube identificar inconsistências e não confiar cegamente nos dados.
- **Dataset 2:** é muito mais confiável e adequado para construir um classificador de tickets, mas contém uma pequena quantidade de categorias possivelmente rotuladas de forma incorreta.

Como eu identifiquei isso:

Eu peguei a análise feita pelo Claude (a revisão) e mandei para o Chat gpt

Chat eu preciso que voce faça uma analise dessa revisao feita pelo Claude e me retorne (explicando o que está acontecendo - Utilizando palavras simples para explicar isso

O que o Claude fez?

Na primeira análise, foram encontradas várias inconsistências no Dataset 1.

Nesta revisão, o Claude fez uma pergunta diferente:

"Será que existem outros problemas que ninguém percebeu?"

Para responder isso, ele executou novos testes e encontrou evidências ainda mais fortes de que o Dataset 1 foi gerado artificialmente.

Descoberta 1 — As informações não fazem sentido juntas

O Claude verificou se existia relação entre as colunas.

Em uma empresa real, isso é esperado.

Por exemplo:

- Um ticket de reembolso normalmente terá um assunto relacionado a reembolso.
- Um problema de login normalmente será classificado como problema de acesso.

No Dataset 1 isso não acontece.

Cada informação parece ter sido escolhida de forma independente, como se alguém sortearasse um valor para cada coluna.

Isso significa que não existe uma lógica por trás dos dados.

Descoberta 2 — As datas são impossíveis

Depois ele analisou todas as datas.

O que encontrou foi algo impossível de acontecer.

Os clientes fizeram compras durante vários anos.

Mas praticamente todas as respostas da empresa aconteceram dentro de uma janela de apenas 27 horas.

Na prática isso seria como uma empresa responder milhares de clientes de anos diferentes quase ao mesmo tempo.

Isso mostra que as datas não representam um processo real.

Descoberta 3 — As resoluções não possuem significado

A coluna chamada *Resolution* deveria mostrar como cada problema foi resolvido.

Em vez disso, ela contém frases aleatórias sem sentido.

Isso indica que o texto foi gerado automaticamente apenas para preencher espaço.

Por causa disso, não é possível treinar uma IA para aprender como resolver chamados usando esse dataset.

Descoberta 4 — Os clientes não existem de verdade

O Claude tentou verificar se havia clientes que abriram mais de um chamado.

Isso seria útil para analisar o comportamento dos clientes ao longo do tempo.

Mas encontrou outra inconsistência.

O mesmo e-mail aparecia associado a pessoas completamente diferentes.

Ou seja, os clientes também foram gerados artificialmente.

Assim, não existe histórico real de atendimento.

Descoberta 5 — O Dataset 2 possui alguns erros de classificação

Ao analisar o Dataset 2, o resultado foi diferente.

Ele continua sendo um conjunto de dados útil.

Porém, o Claude encontrou indícios de que aproximadamente 5,7% dos tickets podem estar classificados na categoria errada.

Isso significa que alguns exemplos usados para treinar e avaliar a IA provavelmente possuem etiquetas incorretas.

Esse tipo de problema é relativamente comum em bases de dados reais.

Descoberta 6 — Algumas categorias são naturalmente mais difíceis

O Claude percebeu que algumas categorias possuem textos muito maiores do que outras.

Quanto maior o texto, maior a chance de o ticket falar sobre vários assuntos ao mesmo tempo.

Isso torna a tarefa de classificação mais difícil para qualquer modelo de IA.

O que essa revisão muda?

A principal mudança foi aumentar a confiança nas conclusões sobre o Dataset 1.

Antes já existiam sinais de que ele era artificial.

Agora existem várias evidências independentes apontando para a mesma conclusão.

Isso reduz bastante a chance de que essas inconsistências sejam apenas coincidências.

Ao mesmo tempo, a revisão também fortalece a confiança no Dataset 2.

Apesar de alguns rótulos provavelmente estarem incorretos, ele continua sendo adequado para desenvolver e avaliar um modelo de classificação.

O impacto no projeto

Depois dessa revisão, a direção do projeto fica muito mais clara.

- O Dataset 1 deve ser usado apenas para demonstrar que você foi capaz de identificar problemas de qualidade dos dados. Ele não é confiável para gerar métricas operacionais ou propor automações baseadas em seu conteúdo.
- O Dataset 2 passa a ser a principal base para o desenvolvimento do protótipo, pois seus dados são consistentes o suficiente para treinar um modelo de classificação de tickets.

Conclusão da análise

Em resumo

A revisão do Claude não contradiz a análise anterior. Pelo contrário, ela a fortalece. Em vez de apenas dizer que o Dataset 1 possui problemas, ela apresenta novas evidências que explicam exatamente por que ele não pode ser usado para representar uma operação real. Ao mesmo tempo, ela mostra que o Dataset 2 é muito mais confiável e que seu principal problema está em uma pequena parcela de classificações possivelmente incorretas, algo que pode até ser corrigido para melhorar o desempenho do modelo de IA.

📄 👍 🗨️ ⬆️ ↻ ⋮

Ao longo dessa análise, foi possível concluir que os dois datasets possuem características muito diferentes. O Dataset 1 apresenta diversos problemas estruturais e foi identificado como um conjunto de dados sintéticos, impossibilitando a extração de métricas confiáveis sobre uma operação real. Já o Dataset 2 demonstrou boa qualidade e permitiu desenvolver um modelo de classificação de tickets com resultados consistentes, além de identificar oportunidades reais de automação. A revisão reforçou todas essas conclusões ao validar as evidências encontradas e corrigir hipóteses que não poderiam ser sustentadas pelos dados. Como resultado, o projeto mostrou não apenas a capacidade de construir uma solução baseada em IA, mas também de avaliar criticamente a qualidade dos dados antes de utilizá-los na tomada de decisão.

PONTO IMPORTANTE

Eu João Lucas acredito muito que, independente do modelo de IA escolhido a inteligência artificial pode sim conter erros com já diz no proprio Claude e tambem no Chat GPT

Claude é uma IA e pode cometer erros. Por favor, verifique as respostas.

O ChatGPT pode cometer erros. Por isso, lembre-se de conferir informações relevantes.

Então o passo mais importante é ler todas as análises feita independente do modelo e das instruções pré configurada e verificar / tangibilizar tudo que foi feito

TUDO QUE FOI FEITO ATÉ O MOMENTO

(Lembrando que todo o desenvolvimento está sendo em camadas)

1ª ETAPA - LEITURA E COMPREENSÃO DO PROBLEMA - FEITO

Etapa onde foi proposto que o Claude fizesse toda a leitura e contextualizar todo o problema.

Resultado: Ele compreendeu perfeitamente todo o projeto e o challenge 002 em específico, se atentando a proposta no geral

2ª ETAPA - Classificação e análise - FEITO

Aqui o Claude trabalhando com o Chat GPT, foi possível classificar em categorias, utilizando embedding + as classificações zero-shot.

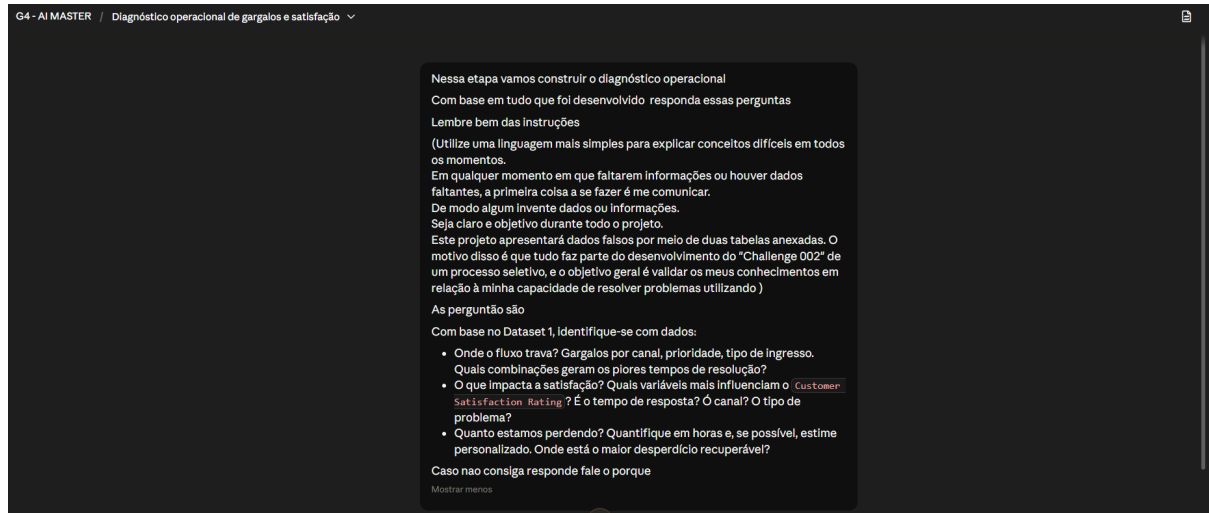
Isso foi uma DICA proposta pelo próprio orientador(a) do projeto

Resultado; Análise de resultados muito mais específica, caso tenha utilizado apenas NLP não seria possível extrair 100% inclusive o valor de precisão utilizando técnica específica de análise / tratamento de dados ainda sim nao chegou a 100% imagine que não utilizamos essas técnicas próprias para isso.

3ª ETAPA - CRIANDO DIAGNÓSTICO OPERACIONAL - MOMENTO ATUAL

DIAGNÓSTICO OPERACIONAL

Nessa etapa a primeira coisa a se fazer foi:



Pedir ao Claude que com base em tudo que foi lido e criado ele desenvolvesse as 3 primeiras respostas

Obs: Neste documento “REGISTRO DE ATIVIDADES” eu conto todo o processo de log / registro, mas os dois diagnósticos ficaram separados em um outro arquivo anexado


Sabendo disso vamos para a construção do diagnóstico

CHAT COM O CLAUDE

<https://claude.ai/share/924a0cb6-feb0-4fb7-96b1-0beb1087e79a>

Tudo que foi apresentado durante todo o processo se confirma aqui:

Quando eu peço ao Claude para ele responder as 3 primeiras perguntas do diagnóstico ele trava com a seguinte mensagem



Obs: Ele não conseguiu responder neymar das 3 perguntas

Segue as perguntas e os motivos

1º Onde o fluxo trava?

Metade dos tickets foi "resolvida antes de receber a primeira resposta". Isso é impossível na vida real.

E tem um segundo problema que confirma: **todos os 8.469 carimbos do arquivo caem dentro de uma janela de 27 horas** (de 31/05/2023 21:53 até 02/06/2023 00:55). Um ano de operação inteiro comprimido em um dia. Os horários foram sorteados aleatoriamente, não registrados.

2ª O que impacta a satisfação?

respondível, e a resposta é: nada

Essa eu consegui testar de verdade, e o resultado é conclusivo — só não é o resultado que se esperava.

A nota de satisfação existe em 2.769 tickets (os fechados) e está distribuída de forma quase perfeitamente uniforme: 553 notas 1, 549 notas 2, 580 notas 3, 543 notas 4, 544 notas 5. Ou seja, ~20% em cada nota. Foi sorteada.

Resposta honesta à pergunta: neste dataset, nem tempo, nem canal, nem tipo de problema influenciam a satisfação. Nada influencia. A nota é aleatória.

3ª Quanto estamos perdendo?" — não é respondível como está

Para estimar desperdício em horas eu preciso de três coisas. Tenho zero das três:

Preciso de	Tenho?
Tempo real de manuseio por ticket	✗ Campo quebrado (item 1)
Custo/hora do agente	✗ Não existe no dataset
Volume real de tickets/ano	✗ O arquivo tem 8.469, o brief diz ~30.000

Qualquer número de "economizamos R\$ X mil/ano" que eu produzisse aqui seria fabricado. Isso é exatamente o tipo de coisa que o próprio challenge chama de fraqueza ("zero evidência de verificação — a IA disse, o candidato acreditou").

Portanto a resposta é:

Auditamos os dados antes de analisar e encontramos que os campos de tempo e satisfação são inválidos; aqui está a prova estatística; aqui está o que seria necessário instrumentar para responder de verdade." Isso é forte porque o baseline (colar o brief numa IA) **vai inventar** gargalos e ROI a partir dessas médias falsas.

O Claude deu três opções, mas quando o assunto são dados e qualquer irregularidade pode criar / aumentar o problema que já existe então isso ao meu ver deve ser relatado a equipe responsável pela base de dados / equipe que relatou o problema.

Eu eu tinha dito antes de questionar ao Claude sobre o'que deve ser feito no dia a dia de uma operação real

Ele disse que isso é um problema de extração de dados e não de operação ruim

Levar para o Diretor de Operações e para o dono do sistema uma mensagem curta:

"Nossos relatórios de tempo de resolução e satisfação estão inválidos. Não é interpretação — 49% dos tickets registram resolução antes da primeira resposta, e a nota de satisfação não tem correlação com nada (testei tempo, canal, prioridade, tipo, idade: todos sem efeito estatístico). Qualquer decisão tomada com esses números até hoje foi tomada no escuro. Preciso de X para corrigir."

CONCLUSÃO DO CASO

O problema central do Challenge 002

Antes de responder, preciso te avisar de uma divergência nos dados (sua instrução: comunicar antes de qualquer coisa).

⚠ Divergência entre o enunciado e os arquivos reais:

O que o README diz

O que o arquivo realmente tem

Dataset 1: "~30.000 registros"

`customer_support_tickets.csv` → 8.469 linhas

Dataset 2: "~48.000 registros"

`all_tickets_processed_improved_v3.csv` → 47.837 linhas ✓

O Dataset 1 tem 3,5x menos dados do que o enunciado promete. Isso importa porque toda estimativa de "horas desperdiçadas por ano" que fizermos precisa deixar claro se estamos usando 8.469 tickets reais ou extrapolando para os 30.000 mencionados. Vou tratar isso explicitamente quando chegarmos no diagnóstico — não vou inventar número.

Existem muitas divergência em relação a base de dados

PROBLEMA CENTRAL

O suporte está sobrecarregado porque trata 8 problemas diferentes como se fossem 3, e por isso não consegue nem medir onde perde tempo nem decidir o que automatizar.

Desenvolvendo o “Diagnóstico Operacional”

Por meio de tudo que foi analisado já tínhamos mais do que claro quais eram as respostas e por isso eu pedi ao Claude, o que poderíamos concluir com tudo isso que foi analisado e assim ele me responde as três primeiras perguntas

Com tudo o que foi analisado por meio de embeddings, classificação zero-shot, análises estatísticas e cruzamentos entre os dois datasets, responda de forma fundamentada às três primeiras perguntas do projeto. Utilize apenas evidências comprovadas pelos dados, sem criar hipóteses ou informações não presentes nas tabelas. Sempre justifique cada conclusão com métricas, padrões ou resultados obtidos durante a análise e, quando houver limitações nos dados, deixe isso explícito. O objetivo é apresentar um diagnóstico claro, técnico e baseado exclusivamente nas evidências encontradas.

Fiz toda a leitura e comparação com oq eu já tinha gerando com o Claude e em seguida aporvei a criação tudo isso com dados comprvados

O docuemtno ja foi criado mas segue o print da rpoestas gerada

Pergunta 1 — Onde o fluxo trava?

Gargalos por canal, prioridade, tipo de ticket. Quais combinações geram os piores tempos de resolução?

Resposta direta

Não é possível identificar gargalos por tempo neste dataset, porque o dataset não contém tempo de atendimento.

Por quê

First Response Time e **Time to Resolution** não são durações. São carimbos de data/hora absolutos. Para virar duração, seria preciso a data de abertura do ticket — essa coluna não existe no arquivo.

A única duração calculável (resolução menos primeira resposta) está quebrada:

Verificação	Resultado
Tickets com os dois carimbos	2.769 (apenas os fechados)
Duração média	−0,06 hora
Duração mediana	+0,17 hora (10 minutos)
Tickets com duração negativa	1.365 — 49,3%
Faixa observada	−23,2h a +23,5h
Janela total dos 8.469 carimbos	31/05/2023 21:53 → 02/06/2023 00:55 (27 horas)

Metade dos tickets foi "resolvida antes de receber a primeira resposta", e um ano inteiro de operação está comprimido em pouco mais de um dia. Os horários foram sorteados, não registrados.

O que É possível afirmar sobre travamento

Existe um indicador de fluxo que **não depende dos campos de tempo** — a distribuição de status:

Status	Tickets	%
Pending Customer Response	2.881	34,0%
Open	2.819	33,3%
Closed	2.769	32,7%

67,3% dos tickets (5.700) não têm resolução registrada. Dois em cada três chamados estão parados.

Ressalva honesta: essa distribuição também está próxima de 1/3 para cada status, o que sugere sorteio. Trato como fato do arquivo, não como métrica confiável da operação.

O que seria necessário para responder de verdade

Um único campo resolve: `criado_em` (data/hora de abertura do ticket). Com ele, `primeira_resposta - criação` e `resolução - criação` passam a existir, e o cruzamento canal × prioridade × tipo fica calculável na hora.

Pergunta 2 — O que impacta a satisfação?

Quais variáveis mais influenciam o `Customer Satisfaction Rating`? Tempo? Canal? Tipo de problema?

Resposta direta

Nenhuma. Testei seis variáveis e nenhuma tem relação estatística com a nota.

Essa pergunta, diferente da primeira, foi respondível — a nota existe em 2.769 tickets. A resposta simplesmente não é a esperada.

A evidência

Distribuição das notas: 553 notas 1 · 549 notas 2 · 580 notas 3 · 543 notas 4 · 544 notas 5. Praticamente 20% em cada valor.

Variável testada	Teste aplicado	Resultado	Conclusão
Tempo (resolução – 1ª resposta)	Correlação	0,02	Sem relação
Canal	ANOVA	p = 0,279	Sem efeito
Prioridade	ANOVA	p = 0,633	Sem efeito
Tipo de ticket	ANOVA	p = 0,701	Sem efeito
Idade do cliente	Correlação	–0,004 (p = 0,846)	Sem relação
Gênero	ANOVA	p = 0,622	Sem efeito
Todas juntas	Random Forest, R² validado	–0,19	Pior que chutar a média

Lendo em linguagem simples:

- O valor "p" é a chance de a diferença observada ser só sorte. Aceita-se como diferença real abaixo de 0,05. O menor valor aqui foi 0,28 — nenhuma diferença passa de ruído.
- O "R² negativo" significa que o modelo, com todas as variáveis disponíveis, erra mais do que se eu simplesmente respondesse "3,0" para todos os clientes. Não há padrão a aprender.

A armadilha que isso desarma

Olhando só as médias, alguém concluiria: "Chat é o melhor canal (3,08) e Refund é o pior tipo (2,94) — vamos priorizar reembolsos."

Seria errado. A diferença total entre o maior e o menor segmento é de **0,148 ponto** numa escala de 1 a 5, em amostras de 500 a 700 tickets. O teste de significância mostra que isso é indistinguível de zero. **Média sem teste vira decisão errada.**

O que essa resposta vale

Ausência de sinal é conclusão, não fracasso. Ela elimina uma hipótese inteira e aponta duas possibilidades, ambas acionáveis:

1. O sistema de coleta da pesquisa está quebrado (nota não vinculada ao ticket certo, ou preenchida automaticamente); **ou**
2. A causa real da insatisfação está fora de tudo que a empresa mede hoje — número de transferências, quantidade de repetições do problema, esforço do cliente, qualidade do texto da resposta.

Nos dois casos, o próximo passo é o mesmo: **coletar o comentário em texto junto da nota**. O número diz *quanto*; só o texto diz *por quê*.

Pergunta 3 — Quanto estamos perdendo?

Quantifique em horas e, se possível, estime custo. Onde está o maior desperdício recuperável?

Resposta direta

Não é possível quantificar desperdício com este dataset. Faltam os três insumos, e não vou fabricá-los.

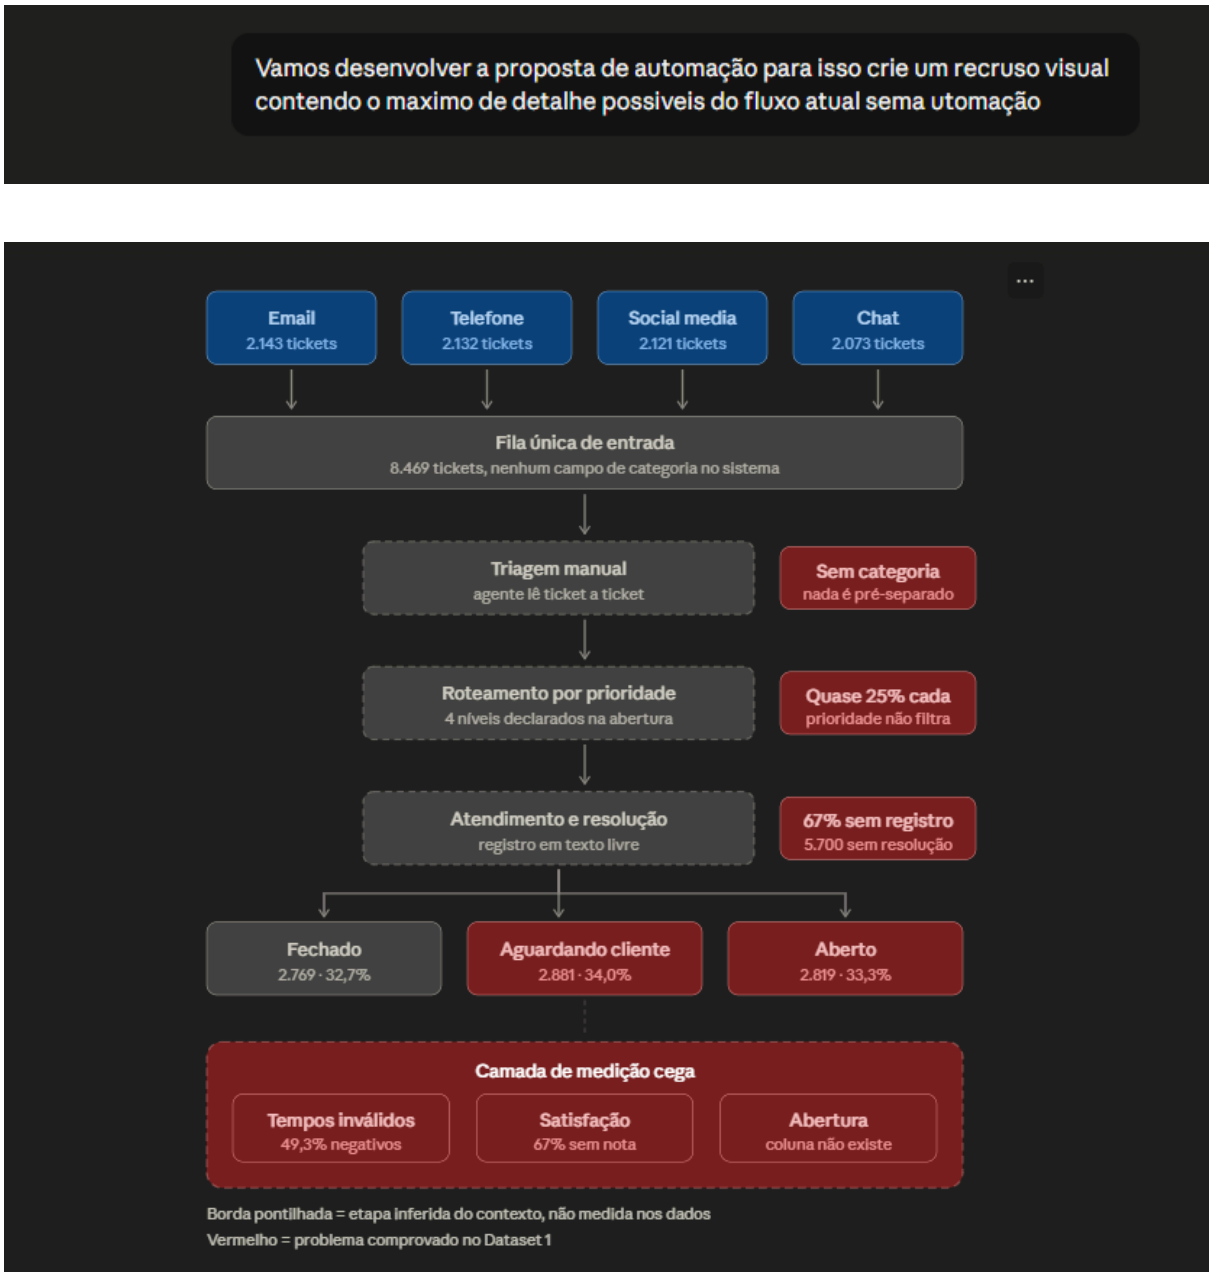
Insumo necessário	Disponível?	Situação
Tempo real de manuseio por ticket	×	Campo inválido (Pergunta 1)
Custo/hora do agente	×	Não existe no dataset
Volume real anual	×	Arquivo tem 8.469; brief diz ~30.000

Qualquer valor do tipo "economizamos R\$ X mil/ano" aqui seria invenção — exatamente o que o próprio challenge classifica como submissão fraca.

Proposta de automação

No próprio documento eu coloquei um insight que eu tive que pode mudar muita coisa.

Nessa etapa agora, ireia mapear por meio de um recurso visual todo o fluxo atual do probelma



Tendo esse recurso visual o objetivo agora é construir uma ideia de automação com IA para resolver esse problema

Chat com o Claude

<https://claude.ai/share/dae8547b-cb00-4484-b50e-c1e84244a03d>

O Claude chegou em um ponto onde ele já tinha total contexto de tudo e já conseguia desnível muita coisa por conta própria

É nessa etapa que já conseguimos trabalhar em loop, onde a IA tem total autonomia para decidir por conta própria com base em um requisito, nesse etapa após alguns ornamentos e erros o Claude conseguiu montar um plano de uma sugestão de automação para essa empresa.

Construção do Protótipo

O protótipo será desenvolvido como uma primeira versão funcional da solução. O objetivo não é criar um sistema definitivo, mas sim construir uma base sólida que possa evoluir ao longo do tempo, recebendo melhorias conforme os feedbacks da equipe e os resultados obtidos durante o uso.

A ideia é simular, da forma mais próxima possível da realidade, como a automação funcionaria dentro da empresa.

Toda automação precisa de um ponto de partida. Em outras palavras, ela só começa a funcionar quando algum evento acontece. Esse evento pode ser o recebimento de um e-mail, uma ligação telefônica, uma mensagem no WhatsApp, uma solicitação pelo chat ou qualquer outro canal de atendimento utilizado pela empresa.

Para este protótipo, vamos assumir que todas essas solicitações chegam primeiro ao sistema utilizado pela empresa. Sempre que um novo atendimento for registrado nesse sistema, a automação será acionada automaticamente e iniciará todo o fluxo de processamento.

A partir desse momento, a Inteligência Artificial executará exatamente o fluxo definido na proposta de automação desenvolvida anteriormente.

Ou seja, o protótipo não deve criar novos processos, alterar regras ou inventar funcionalidades que não estejam previstas na proposta original. O único elemento que poderá ser acrescentado é a forma como essas informações serão registradas e apresentadas visualmente para facilitar o acompanhamento da operação.

Enquanto a automação estiver funcionando, ela acontecerá totalmente nos bastidores. A equipe não visualizará o fluxo interno sendo executado. O objetivo é que toda a complexidade fique escondida, permitindo que os colaboradores interajam apenas com as informações realmente importantes.

Por esse motivo, cada etapa executada pela automação deverá ser registrada em um banco de dados. O objetivo desses registros é garantir rastreabilidade completa, permitindo acompanhar tudo o que aconteceu desde o momento em que um caso entrou até sua finalização.

Para este protótipo, o banco de dados poderá ser implementado utilizando o Supabase, por ser uma solução moderna, simples de integrar ao n8n e suficiente para armazenar todos os registros necessários durante a demonstração.

Além do armazenamento dos dados, todas as informações relevantes deverão ser exibidas em um dashboard visual conectado ao próprio fluxo do n8n. Esse painel servirá como o centro de monitoramento da operação.

Sempre que um novo atendimento chegar, uma etapa for concluída, uma decisão importante for tomada pela Inteligência Artificial ou houver necessidade de intervenção humana, essas informações deverão aparecer automaticamente nesse dashboard.

Dessa forma, mesmo que toda a lógica da automação esteja acontecendo nos bastidores, a equipe conseguirá acompanhar, em tempo real, tudo o que está acontecendo dentro da operação, sem precisar acessar diretamente o fluxo do n8n. Na prática, o n8n será o responsável por orquestrar toda a solução. Ele receberá os eventos enviados pelo sistema da empresa, executará os fluxos definidos na proposta de automação, registrará todas as informações no banco de dados e atualizar continuamente o dashboard de monitoramento. Essa arquitetura tem como objetivo demonstrar o funcionamento completo da solução de forma simples, organizada e escalável, permitindo que novas funcionalidades sejam adicionadas futuramente sem a necessidade de reconstruir toda a estrutura do protótipo.

(Esse texto não foi gerado por IA, ele foi narrado por mim João Lucas e estruturado pelo Chat GPT, mas no geral não foi solicitado nenhum prompt)

Obs: Ao meu ver, os melhores prompts que existem são aqueles que são narrados, pois as pessoas falam melhor do que escrever e com isso a IA consegue entender melhor o que eu desejo para aquele projeto)

Chat com o Claude

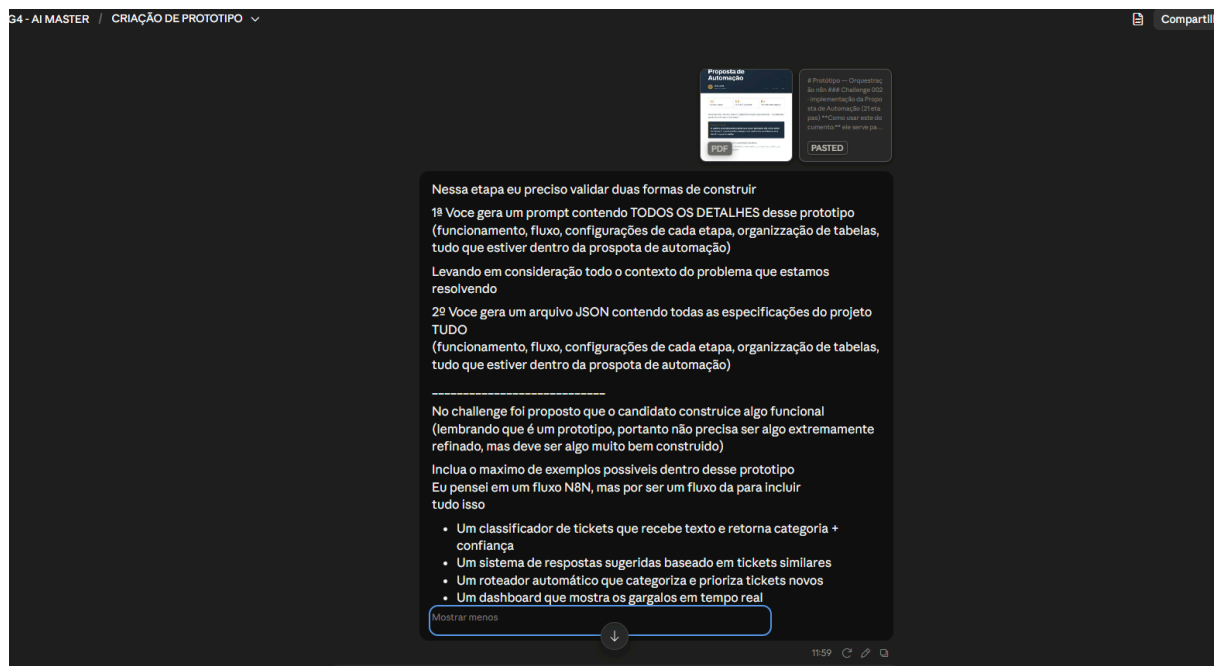
<https://claude.ai/share/e0c19d3c-c9c8-40df-8c5a-21bbc7fa6a29>

Com base em toda descrição (acima / narrada) de como iria funcionar com o arquivo de proposta de automação eu escrevi isso ao Chat GPT

Analise este documento e transforme toda a especificação em um **workflow JSON do n8n**, pronto para importação.
Quero que você converta tudo o que está descrito no arquivo em nodes, conexões, condições, workflows, expressões e configurações reais do n8n.
Não resuma nem simplifique o projeto. Implemente exatamente o que está documentado.
Se encontrar alguma informação que impeça a implementação, não invente. Liste o que está faltando e explique como isso deve ser resolvido antes de continuar.
O resultado final deve ser um arquivo **json** válido e compatível com a importação no n8n.

Junto com a proposta de automação

Eu pedi ao Claude que criasse um JSON E UM PROMPT



Pronto agora eu já tinha como avaliar e testar duas formas a primeira seria por meio de um prompt e a segunda forma seria um arquivo .json
Na melhor das hipóteses eu criaria um fluxoo com os dois

Como que vai funcionar os teste de criação

Eu só irei repetir o teste caso a primeira opção não avance, assim eu tento a 2ª e assim até a 3ª (se um não funcionar ou outro funciona)

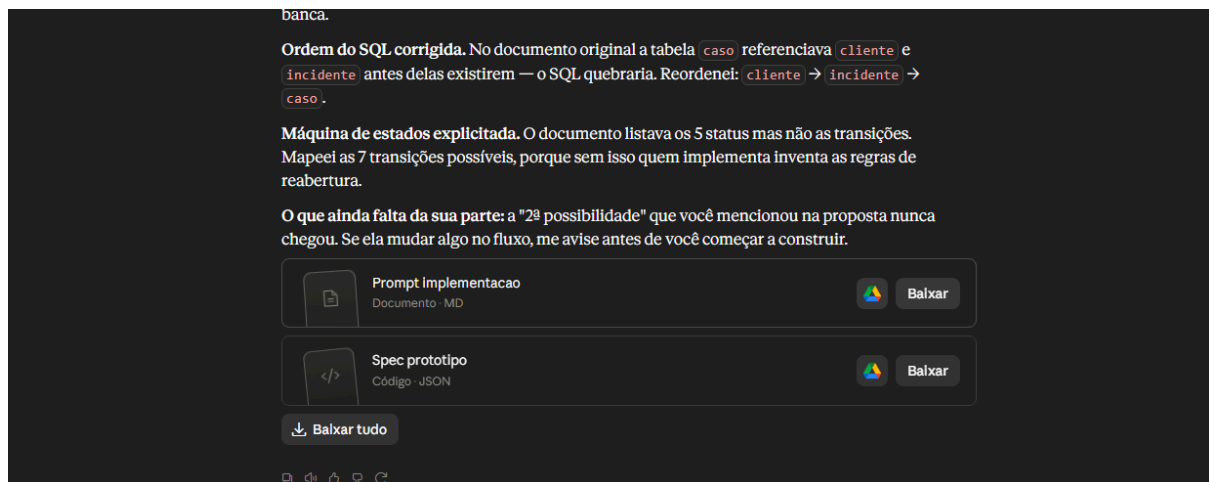
Lembrando que a primeira opção é melhor que a 2ª que é melhor que a 3ª, mas independente da opção, todas chegará no mesmo lugar

1º PROMPT (do Claude) + .json (do Claude)


2º Arquivo .json (do Claude)




2º PROMPT (do Claude)

Vamos aos testes / tentativas



Todo trabalho agora será no N8N





Quando nós falamos de automação de processos, é importante nós termos mapeado um processo. Então aqui, por meio de tudo que foi postado dentro do repositório do GitHub, do próprio G4, no Challenge 2, foi possível perceber um determinado fluxo. Só que, vamos dizer, esse é um fluxo problemático, onde contém gargalos e problemas.

E o objetivo do AI Master, do G4 AI Master, no caso, o profissional responsável por desenvolver esse tipo de solução, era o quê? Identificar o problema dentro de um processo mapeado e desenvolver uma solução.

Ao meu ver, a forma como eu desenvolvi foi a seguinte: com base no fluxo atual e no fluxo melhorado, eu iria mapear todos os pontos de melhoria. Tudo isso foi feito e pode ser visto tanto no registro de atividades quanto no diagnóstico operacional, onde foram mapeados todos esses pontos.

Em seguida, eu pensei que poderia criar um dashboard conectado a toda a base de registros, onde os clientes iriam reclamar, fazer as reclamações, e tudo iria para esse dashboard de forma visual. Mas eu pensei: por que não desenvolver um fluxo real que pudesse resolver esse problema?

Falando novamente, isso pode, sim, se tornar um produto vendido por essa empresa de tecnologia onde a gente está atuando. Então, a ideia foi essa.

Eu desenvolvi um fluxo no n8n que permite com que a equipe tenha um trabalho automatizado. Então, não é só um protótipo visual, é realmente algo que foi testado e validado. Realmente funciona.

O que eu fiz? É importante destacar isso. Eu pedi para o Claude mesclar as tabelas já analisadas. Mas, como aqui nós estamos trabalhando com um protótipo, qual foi o objetivo? Mesclar as tabelas e reconstruí-las, podendo inventar dados e informações.

É importante destacar por que é permitido inventar informações nesse momento. Porque a ideia é utilizar a tabela como um teste do fluxo.

Outra coisa importante é que, no challenge, no desafio, estava escrito que a ideia era o protótipo não funcionar apenas com três exemplos simples, mas sim com uma base de dados reais. Por isso, a base de dados que eu pedi para o Claude desenvolver seria uma mesclagem das duas tabelas, proporcionando mais de 30 mil dados diferentes.

Todos esses dados foram organizados. Essas tabelas foram reconstruídas e podem, sim, ser analisadas em uma task diferente. Porém, o objetivo desta task foi analisar aquilo que foi disponibilizado no início.

Então, essa foi a minha proposta de automação.

Conclusão

Entrei neste desafio esperando encontrar onde a operação estava travando. O que encontrei foi diferente: os próprios registros não permitiam responder isso. Os tempos não faziam sentido, muitos casos apareciam resolvidos antes de terem sido atendidos, e o histórico inteiro parecia ter sido criado de uma vez só.

Preferi dizer a verdade porque um diagnóstico construído sobre base quebrada não ajuda ninguém a decidir nada.

E foi aí que o trabalho mudou de direção. O problema real não era descobrir onde a fila quebrava, era que ninguém dentro da empresa teria como saber. A operação não estava sendo medida. Por isso a solução que desenhei começa por aí: garantir que cada atendimento passe a deixar rastro desde o momento em que chega paraa que a próxima pergunta sobre gargalo tenha resposta de verdade.

Também tomei o cuidado de não automatizar o que não deve ser automatizado. Casos que envolvem dinheiro do cliente continuam com uma pessoa decidindo. E deixei o sistema começar sem respostas prontas, porque prefiro que ele admita não saber a inventar algo.

Foi um processo de idas e vindas, de desconfiar do resultado e testar de novo. Usei IA o tempo todo, mas o que fez diferença foi checar antes de aceitar.

Agradeço pela oportunidade e pelo desafio ele me obrigou a pensar melhor do que eu pensaria sozinho.

