Auditoria da entrega — G4 Challenge 002

Nov 6, 2026 · @Rafael Moraes

Pedido

Rafael pediu uma auditoria adversarial da submissão do Challenge 002 e anexou quatro arquivos: `README-submissao.md`, `diagnostico.md`, `automacao.md` e `prototipo.html`. O pedido, na íntegra:

> Você é um avaliador exigente do processo seletivo AI Master do G4 (Challenge 002 — Redesign de Suporte). Os critérios do G4 são: entendeu o problema antes de executar; usou ambos os datasets; diagnóstico com números concretos; automação realista (automatizar 100% é red flag); sabe onde a IA ajuda e onde o humano é insubstituível; protótipo funciona com dados reais e não com exemplos escolhidos; alguém consegue agir com base na entrega.
>
> Sua tarefa é tentar DERRUBAR esta entrega. Não elogie. Para cada problema, diga onde está, por que é um problema e qual o risco na avaliação. Procure especialmente:
>
> 1. Números que não se sustentam, contradições entre documentos ou entre documento e protótipo.
> 2. Conclusões que vão além do que os dados permitem.
> 3. Premissas fracas no cálculo de retorno.
> 4. Falhas no protótipo: abra o prototipo.html e tente quebrá-lo com tickets em português e inglês (casos ambíguos, sarcasmo, dois assuntos no mesmo texto, cancelamento disfarçado, urgência falsa).
> 5. O que um diretor de operações não entenderia ou não conseguiria usar.
> 6. O que está faltando em relação ao briefing.
>
> Termine com: os 3 problemas mais graves, em ordem.

Método

Os números principais da entrega batem com os dados embutidos no protótipo; os problemas estão em outro lugar.

- O motor de triagem foi extraído do `prototipo.html` e executado no Node, com o mesmo modelo e as mesmas regras do navegador.
- As métricas foram recalculadas a partir dos dados de avaliação embutidos (9.568 tickets de teste).

- 48 tickets adversariais em português e inglês foram passados pelo motor (lista completa no anexo).
- A fonte citada para os 40 min de espera (HappySignals) foi conferida na web.

Métrica	Entrega	Recalculado
Acerto geral	86,1%	86,1%
Encaminhados pela IA (limiar 80%, 90% em Administrative rights)	64,4%	64,4%
Acerto nos encaminhados pela IA	96,7%	96,7%
Acerto quando o modelo tem dúvida	67%	67,0%
Categoria certa entre as 2 opções dadas ao atendente	não citado	90,5%
Acerto na fila de demonstração (80 tickets)	não citado	86,3%

A fila de demonstração tem acerto igual ao do teste completo, o que indica que não foi escolhida a dedo.

1. Números frágeis e contradições

Os números de acerto se sustentam; o que não se sustenta é como foram escolhidos e o que fica de fora do cálculo.

- **O limiar foi escolhido nos dados de teste.** O README diz "limiar de confiança medido em dados de teste", e os 96,7% são medidos nos mesmos 9.568 tickets. O efeito numérico deve ser pequeno, mas um avaliador técnico verá erro de método. O correto seria separar uma parte para validação.
- **Os 64,4% contam só o classificador.** As regras de Retenção, RH, Aprovação e "Aguardando cliente" vêm antes e tiram tickets do automático, mas esse desconto não entra na cobertura nem no retorno. Na fila de demonstração, 48 de 80 tickets passam do limiar e só 45 são encaminhados pela IA.
- **A fonte dos 40 min não diz 40 min.** O diagnóstico atribui "espera do cliente por reencaminhamento: 40 min" à HappySignals. O relatório deles fala em média de 1 h 46 min de trabalho perdido por reatribuição, medido com funcionários atendidos pela TI interna, não com clientes. Os 40 min podem ser uma escolha conservadora, mas do jeito que está escrito o número não bate com a fonte.

- **"Premissas validadas pelo Rafael"** é o próprio candidato validando as próprias premissas. Os 20% de erro manual ("trocar pelo dado real") geram todo o resultado de 3.231 reencaminhamentos evitados e 2.154 h de espera. Com erro real de 10%, os dois números caem mais da metade.
- **Há uma inconsistência no próprio cálculo.** Os tickets que vão para "Atendente escolhe" são calculados com os mesmos 20% de erro manual. Mas o atendente recebe duas opções, e a categoria certa está entre elas em 90,5% dos casos. O modelo de retorno ignora a ferramenta que ele mesmo propõe.
- **O retorno não tem custo de implantação.** Retreino, integração com Power Automate ou Apps Script, auditoria semanal e manutenção das regras não aparecem. R$ 23 mil por ano brutos podem virar zero líquido.
- **O mesmo item tem dois nomes.** O diagnóstico diz "90% em Administrative rights" e a automação diz "90% em Suporte a software".

2. Conclusões além dos dados

A entrega critica o baseline por generalizar a partir de dados ruins e comete a mesma generalização no resumo executivo.

- **"A operação não se mede"** aparece como achado no resumo executivo. O próprio diagnóstico diz que as conclusões valem "para este arquivo, não para a operação real". Um arquivo sintético não permite concluir nada sobre como uma operação se mede.
- **O achado A vira recomendação** ("triagem de prioridade automática") apoiado em dados que a própria entrega chama de gerados por computador.
- **"Pending" é contado como travado.** 34% dos tickets estão aguardando o cliente, o maior grupo. A solução acrescenta mais perguntas ao cliente: assunto, impacto e duas perguntas de cancelamento. Se o diagnóstico vale alguma coisa, a proposta pode aumentar justamente esse grupo, e isso não é discutido.

3. Premissas fracas no retorno

O retorno depende de premissas sem medição e de um custo que não aparece.

Premissa	Problema	Efeito no resultado
20% de erro manual	Sem fonte; "validada" pelo próprio candidato	Gera todos os 3.231 reencaminhamentos e 2.154 h de espera evitados

Premissa	Problema	Efeito no resultado
40 min de espera por reencaminhamento	A fonte citada diz 1 h 46 min e mede funcionários, não clientes	Atribuição errada, mesmo se o número for conservador
3 min de triagem liberados por inteiro	O time que recebe o ticket ainda precisa lê-lo	Superestima as 1.154 h
Cobertura de 64,4%	Ignora os tickets desviados pelas regras	Superestima volume e horas
Custo de implantação	Ausente	R$ 23 mil/ano são brutos, não líquidos

4. Protótipo: o que quebrou

O protótipo quebrou em cancelamento disfarçado, casos sensíveis, negação, urgência falsa e dois assuntos no mesmo texto.

Ticket	Resultado	Problema
"Preciso cancelar a reserva da sala e também quero cancelar meu contrato"	Atendente escolhe, P3	**O bug dado como corrigido continua.** A exclusão de reunião vale para o texto inteiro e anula qualquer cancelamento
"Quero encerrar minha conta"	**IA encaminhou, Acesso, 100%**	O pedido de cancelamento vai para a TI desativar a conta
"Please close my account, I'm moving to another provider"	IA encaminhou, Acesso, 85%	Idem, mesmo com concorrente explícito
"Estou pensando seriamente em procurar outro fornecedor" / "Não quero mais usar o serviço de vocês"	Aguardando cliente	A regex só pega "trocar de fornecedor"
"I want my money back" / "We are evaluating other vendors"	Atendente escolhe	Não vai para a Retenção

Ticket	Resultado	Problema
"Não quero cancelar, só quero entender a fatura"	**Retenção**	A negação vira risco de perder o cliente
"Estou sofrendo assédio moral do meu gestor"	**Aguardando cliente: a IA faz perguntas simples**	O caso mais sensível de RH recebe um questionário automático
"Vazou a planilha de salários de todo mundo no drive compartilhado"	**IA encaminhou, Armazenamento, P3**	Vazamento vai sozinho com prioridade normal ("salários" no plural escapa da regra)
"Acho que cliquei num link de phishing e digitei minha senha"	**IA encaminhou, Acesso, P3**	Segurança não está na lista do que nunca é automatizado
"Quero denunciar um caso de fraude no setor de compras"	Atendente escolhe, P3	Denúncia tratada como ticket comum
"Não é urgente, mas o mouse está falhando"	**P2**	Negação sobe a prioridade
"URGENTE!!! preciso trocar o papel de parede"	P2	Urgência falsa aceita
"Planned outage tonight 10pm, FYI no action needed"	**P1**	Manutenção programada vira crise; na fila real, "planned outage assessment" também vira P1
"Ninguém da minha equipe consegue acessar o ERP"	IA encaminhou, **RH**, P3	Impacto coletivo não detectado e categoria errada
"O servidor caiu e o financeiro inteiro está parado"	P2	Deveria ser P1
"Meu monitor parou e também preciso de acesso à pasta do financeiro"	IA encaminhou, Armazenamento, 100%	Dois assuntos: o monitor some sem aviso
"Fui cobrado duas vezes este mês" / "Quanto custa o plano empresarial?"	Aguardando cliente	Cobrança não existe no modelo (ver problema grave 1)

Mais quatro pontos do protótipo:

- **Cerca de 10 dos ~40 tickets em português** não tinham nenhuma palavra conhecida pelo modelo e caíram em "Aguardando cliente". O glossário cobre o jargão de TI, não a forma como um cliente brasileiro escreve.
- **"Importance high" no cabeçalho do e-mail vira P2** (9 dos 13 P2 da fila). Isso contradiz a regra "o cliente nunca é perguntado sobre urgência": a marcação feita pelo remetente vale.
- **A pergunta "quem mais está afetado?" é uma pergunta de urgência disfarçada.** Responder "várias equipes ou clientes" leva direto a P1.
- **"Correção salva. Ela entra no próximo treino do modelo"** é falso no protótipo: nada é guardado (o único uso de armazenamento é o idioma). Quem abrir o código encontra isso.

5. O que o diretor não entenderia

A entrega fala a língua de quem fez a análise, não a de quem decide.

- Termos como "limiar", "TF-IDF", "Kruskal-Wallis", "permutação, p = 0,26" e "paridade Python × JavaScript" aparecem sem tradução para decisão.
- "Suporte a software (Administrative rights)" tem um nome na interface e outro no diagnóstico.
- Não diz quem faz o quê na "semana 1", quanto custa nem qual é o critério para desligar a IA se o acerto cair.
- A aba de retorno tem 6 premissas editáveis e nenhuma recomendação do tipo "decida X até tal data".

6. O que falta em relação ao briefing

Quatro itens pedidos no briefing não estão respondidos, e a submissão ainda tem campos em branco.

- **Respostas sugeridas e detecção de duplicatas** estão no briefing e não são discutidas. Falta pelo menos dizer por que ficaram de fora.
- **"Onde está o maior desperdício recuperável?"** não é respondido. A tabela de desperdício é o ganho da proposta, não o desperdício atual.
- **"Justifique com exemplos dos dados"** o que não automatizar: as regras de RH, Retenção e privilégio não citam nenhum ticket real dos datasets.

- **O cruzamento é só de papéis, não de dados.** Rodar o classificador nas descrições do Dataset 1, mesmo com os marcadores, mostraria que Billing, Refund e Cancellation não cabem nas 8 categorias. Isso seria um cruzamento real e provaria o problema grave 1.
- **Ainda em branco:** "o que eu adicionei", LinkedIn, link público, data de envio e gravação de tela.

Os 3 problemas mais graves

1. **O classificador resolve o problema de outra operação.** O briefing é suporte ao cliente de uma empresa de tecnologia: o Dataset 1 tem Billing, Refund e Cancellation, e o desafio fala em satisfação do cliente. O modelo, as 8 categorias, os 86,1%, os 64,4% e todo o retorno vêm de um help desk de TI interno (ponto, férias, direitos de admin). O protótipo junta "Procon/reembolso" e "folha de ponto" na mesma fila, e "fui cobrado duas vezes" não tem para onde ir. As limitações dizem "em outra empresa, retreinar", mas o problema é anterior: a medição não vale para a operação do briefing.
    - **Risco:** cair nos critérios "funciona com dados reais" e "entendeu o problema antes de executar".
2. **Os casos em que o humano é insubstituível não estão protegidos.** O bug de cancelamento dado como corrigido continua com dois assuntos no mesmo texto. "Encerrar minha conta" vai sozinho para a TI. Assédio recebe um questionário automático. Phishing e vazamento de salários são encaminhados pela IA com prioridade normal.
    - **Risco:** é o critério central do desafio, e qualquer avaliador que digitar dois ou três casos sensíveis vê a falha na hora.
3. **A prioridade se contradiz e é fácil de enganar.** "Não é urgente" vira P2. "URGENTE" num pedido trivial vira P2. "Importance high" do remetente vira P2. Manutenção programada vira P1, enquanto "ninguém da equipe consegue acessar" fica P3. O princípio declarado ("a prioridade sai de fatos, não da palavra do cliente") não é o que o código faz.
    - **Risco:** somado ao retorno sustentado por uma premissa própria (20%) e uma fonte citada errado (40 min), o avaliador pode concluir que as regras e os números não foram testados contra o que dizem.

Anexo: os 48 tickets de teste

Saída do motor do protótipo, sem alteração. "Termos" = palavras reconhecidas pelo modelo; "Pergunta" = a IA pergunta ao cliente se consegue trabalhar.

Ticket	Quem age	Prioridade	Confiança	Categoria	Termos	Pergunta
Quero cancelar minha assinatura	Retenção	P3	91%	Access	1	não
Vou cancelar o contrato se isso não for resolvido hoje	Retenção	P3	100%	Miscellaneous	2	não
Cancela a reunião de amanhã e me manda o link novo	IA encaminhou	P3	98%	Hardware	3	não
Cancelei a reunião mas o Teams continua mandando convite	IA encaminhou	P3	99%	Hardware	2	não
Preciso cancelar a reserva da sala e também quero cancelar meu contrato	Atendente escolhe	P3	61%	Hardware	2	não
Estou pensando seriamente em procurar outro fornecedor	Aguardando cliente	P3	30%	Hardware	0	não
Vocês são ótimos, nota 10, adorei esperar 3 semanas por um mouse	Atendente escolhe	P3	61%	Hardware	1	não
Parabéns pelo atendimento maravilhoso, só falta funcionar	Aguardando cliente	P3	30%	Hardware	0	não
Não quero mais usar o serviço de vocês	Aguardando cliente	P3	30%	Hardware	0	não
Quero encerrar minha conta	IA encaminhou	P3	100%	Access	1	não
Please close my account, I'm moving to another provider	IA encaminhou	P3	85%	Access	8	não
I want my money back	Atendente escolhe	P3	45%	Hardware	3	não
We are evaluating other vendors for next year	Atendente escolhe	P3	53%	Hardware	8	não
URGENTE!!! preciso trocar o papel de parede	Atendente escolhe	P2	54%	Hardware	1	não
urgente: mudar a cor da minha assinatura de e-mail	IA encaminhou	P2	99%	Miscellaneous	4	não

Ticket	Quem age	Prioridade	Confiança	Categoria	Termos	Pergunta
O sistema está fora do ar para todos os usuários	Atendente escolhe	P1	47%	Hardware	4	não
Ninguém da minha equipe consegue acessar o ERP	IA encaminhou	P3	91%	HR Support	2	não
O site caiu	Atendente escolhe	P3	47%	Hardware	1	sim
o servidor caiu e o financeiro inteiro está parado	Atendente escolhe	P2	73%	Administrative rights	1	não
Meu monitor parou e também preciso de acesso à pasta do financeiro	IA encaminhou	P3	100%	Storage	4	sim
Esqueci minha senha e meu notebook está com a tela quebrada	Atendente escolhe	P3	75%	Hardware	7	sim
Fui demitido e preciso pegar meus arquivos pessoais do notebook	RH	P3	94%	Hardware	2	não
Meu colega está me assediando no trabalho	Aguardando cliente	P3	30%	Hardware	0	não
Estou sofrendo assédio moral do meu gestor	Aguardando cliente	P3	30%	Hardware	0	não
Quero denunciar um caso de fraude no setor de compras	Atendente escolhe	P3	33%	Purchase	1	não
Preciso de acesso de administrador para instalar o Python	Aprovação	P3	33%	Purchase	4	não
Me dá admin aí rapidinho	Atendente escolhe	P3	24%	HR Support	1	não
Can you make me a local admin?	Aprovação	P3	56%	Hardware	7	não
Preciso de acesso ao sistema de folha de pagamento	RH	P3	73%	HR Support	2	não
Tenho uma dúvida	Aguardando cliente	P3	30%	Hardware	0	não
oi	Aguardando cliente	P3	30%	Hardware	0	não
???	Aguardando cliente	P3	30%	Hardware	0	não

Ticket	Quem age	Prioridade	Confiança	Categoria	Termos	Pergunta
Help	Atendente escolhe	P3	51%	Hardware	1	não
Não consigo trabalhar, o computador não liga	IA encaminhou	P2	84%	Hardware	6	não
My laptop is dead and I have a client presentation in 20 minutes	IA encaminhou	P3	98%	Hardware	9	sim
Vazou a planilha de salários de todo mundo no drive compartilhado	IA encaminhou	P3	100%	Storage	2	não
Acho que cliquei num link de phishing e digitei minha senha	IA encaminhou	P3	100%	Access	2	não
I think I got hacked, someone is sending emails from my account	Atendente escolhe	P3	80%	Access	7	não
Recebi um e-mail pedindo meus dados bancários, é golpe?	Atendente escolhe	P3	60%	Storage	1	não
Planned outage tonight 10pm, FYI no action needed	Atendente escolhe	P1	76%	Hardware	8	não
Não é urgente, mas o mouse está falhando	Atendente escolhe	P2	73%	Hardware	2	não
Não quero cancelar, só quero entender a fatura	Retenção	P3	34%	Miscellaneous	1	não
Não tem nada urgente aqui, só uma sugestão de melhoria	Atendente escolhe	P2	56%	Hardware	2	não
Preciso comprar 3 notebooks para os novos estagiários	Atendente escolhe	P3	52%	Hardware	4	não
Quanto custa o plano empresarial?	Aguardando cliente	P3	30%	Hardware	0	não
Fui cobrado duas vezes este mês	Aguardando cliente	P3	30%	Hardware	0	não
A cobrança veio errada de novo, é a terceira vez	Atendente escolhe	P3	67%	HR Support	1	não
meu chefe mandou eu pedir pra liberar acesso ao drive dele	Aprovação	P3	91%	HR Support	4	não

Fontes

- HappySignals: How to Solve the Issue of High IT Service Desk Bounced Ticket Levels: 1 h 46 min de trabalho perdido por reatribuição, em média.
- Arquivos da submissão: `README-submissao.md`, `diagnostico.md`, `automacao.md`, `prototipo.html`.
- Briefing do Challenge 002 (documento do projeto).