Auditoria fase 03 — G4 Challenge 002

Nov 6, 2026 · @Rafael Moraes

Resumo e ressalvas da fase 02

As ações da fase 02 foram cumpridas, exceto os campos em branco; **veredito: pronta com ressalvas**. As regras e o modelo do protótipo são idênticos aos da fase 02 (comparação byte a byte), então a decisão 25 foi cumprida de fato. Os quatro scripts produzem os números do EVIDENCIAS-NUMERICAS. Sobram três frases do README que prometem mais do que foi medido e alguns números antigos no Process Log e no protótipo.

As quatro ações do veredito da fase 02

Ação	Status	Evidência
1. Preencher campos em branco	**Não resolvido**	Ver "Campos em branco"
2. Ajustar "Para o Diretor"	Resolvido, com um problema de palavra	README separa "na TI interna testada, ~6 em 10" de "na sua operação, ~12%"; retorno marcado "hipótese, não estimativa" no README, diagnóstico, automação e protótipo. Mas o README diz "o modelo atual **acerta** pouco (~12% iria sozinho)": 12% é volume encaminhado, não acerto
3. Tirar "todos corrigidos" e declarar o limite	Resolvido por declaração	A frase sumiu do README; limitações citam "vazamento de memória", "discriminar custos", "desistir da assinatura", phishing pelo Teams; piso de 23% medido. A precisão real das regras continua sem medição (só o piso)
4. Não corrigir regex por regex	Resolvido	Decisão 25; motor e modelo idênticos aos da fase 02

Os 3 problemas mais graves da fase 02

Problema	Status	Evidência
Regras erram para os dois lados sem medição	Resolvido por declaração	`automacao.md` seção 3, README, aba Limitações do protótipo; classificador próprio na recomendação 3 e na semana 2–3 do plano
Cancelamento coloquial automatizado	Resolvido por declaração	"Desistir da assinatura" citado como caso que escapa. **O protótipo ainda faz isso**: quem testar vai ver, mas vai encontrar o caso já declarado
Números do diretor misturando as duas operações	Resolvido	Separação TI × clientes em todos os documentos; curva de aprendizado responde "quanto histórico é preciso"

Verificação dos scripts

Os quatro scripts sustentam os números do EVIDENCIAS-NUMERICAS e dos documentos; nenhum número verificável contradiz a entrega.

Script	O que faz	Sustenta os números?
`06_validacao_e_regras.py`	Mesmo corte do teste (20%, estratificado, semente 42 → 9.568); separa 25% do treino para validação; treina no resto; mede validação e teste	Sim: 96,4% / 96,9% e 91,1% / 90,6%. O modelo deste script é menor (treina com 75% do treino), por isso o teste dá 62,1% e não 60,8%. Os documentos citam cada número com a origem certa
`07_curva_aprendizado.py`	Amostras crescentes do treino, sempre no mesmo teste	Sim: a tabela do README (17/27/41/50/64% e 97–99%) bate. A última linha (64,3% / 96,8%) difere 0,1 ponto do modelo principal (64,4% / 96,7%); irrelevante

Script	O que faz	Sustenta os números?
`cross_ds1.js`	Roda o motor completo (regras + modelo) em assunto + descrição dos 8.469 tickets	Sim: 11–12% automático, confiança 60–61%, Hardware 67–68%; os grupos somam 8.469. A saída mostra ainda Retenção em 13–15% de todos os tipos (15% em "Cancellation request", 14% em "Technical issue"), o que confirma que o texto não carrega o tipo
`coverage_with_rules.js`	Aplica o motor aos textos de teste exportados pelo 06	Sim: 60,8% / 96,9% / 33,9% / 90,3%; 506 desvios (220+62+60+56+52+50+6); 118/506 = 23,3%. Recalculado também pelos dados embutidos no protótipo, com o mesmo resultado

Números sem script nestes anexos:

- Paridade 200/200, os testes em português (96,4% / 35,7% / 91,1% em 56 tickets), o baseline (R$ 201 mil) e os testes estatísticos do diagnóstico (scripts 01/02).
- Desses, os números de qualidade dos dados (49,3%, 27 h, 32,5% × 33,7%, as notas de 1 a 5) conferem com o verificador do protótipo.
- O glossário tem ~324 entradas, compatível com "~330".
- Nenhum número contradiz o que pôde ser verificado.

Coerência final e campos em branco

Os números principais batem em todos os arquivos; sobram seis divergências de texto, três frases que prometem mais do que foi medido e sete campos do candidato em branco.

Os números principais batem no README, diagnóstico, automação e protótipo: 86,1%, 60,8%, 96,9%, 33,9%, 90,3%, 5,3%, 23%, 12%, 1.092 h, R$ 21,8 mil, 3.081, 2.054 h, ~568.

Divergências restantes

Onde	Problema
Process Log, Evidências	"DECISIONS.md — **20** decisões"; o cabeçalho e o README dizem 25

Onde	Problema
Process Log, passo 4	"espera do cliente (~40 min)": contradiz a correção (tempo perdido estimado por usuários de TI)
Process Log, passo 5 e tabela de erros	"~R$ 23 mil nosso" e "64% medidos": números antigos (agora R$ 21,8 mil e 60,8%; o README já diz "~9 vezes")
Protótipo, premissa de erro	"Premissa **validada** pelo Rafael"; o diagnóstico diz "premissa **sem fonte**"
Protótipo, nota do retorno	Ainda fala em "tempo de espera"; o resto foi renomeado para "tempo perdido"
DECISIONS, decisão 24	Motivo cita "96,7%" (agora 96,9%). Aceitável como registro histórico

Frases que prometem mais do que foi medido (todas no README)

1. "O modelo atual **acerta pouco** (~12% iria sozinho)": 12% é volume, e foi medido em texto sintético. O acerto na operação de clientes não foi medido.
2. "O limiar mantém o acerto da IA acima de 96% **em qualquer cenário**": medido só no Dataset 2 (TI, inglês, rótulos limpos).
3. "Se o sistema já registra a fila de destino, 3 a 6 meses de histórico **já são os rótulos**": pela premissa da própria entrega, 20% desses encaminhamentos estão errados. O modelo aprenderia os erros; é preciso limpar ou auditar uma amostra antes.

Campos em branco (do candidato)

- LinkedIn
- Link público do protótipo
- "O que eu adicionei que a IA sozinha não faria", no README **e** no Process Log
- Porquê da decisão 4, no DECISIONS
- Data de envio
- Item 10 do Process Log ("Auditoria fase 03: consolidação"), sem conteúdo
- Gravação de tela (desmarcada; só importa se for obrigatória no guia de submissão)

Notas por critério do G4

Critério	Fase 02	Fase 03	Motivo da mudança
Entendeu o problema	7	**8**	Separa TI interna de clientes em todo lugar e mede quanto histórico falta
Usou ambos os datasets	7	**8**	Cruzamento verificado no script
Diagnóstico com números	7	7	Sem mudança
Automação realista	7	**8**	Curva de aprendizado e retorno como hipótese
Onde o humano é insubstituível	5	**6**	Limite declarado e plano de classificador próprio, mas o protótipo ainda automatiza "desistir da assinatura"
Protótipo com dados reais	6	**7**	Todos os números reproduzíveis; limites declarados na própria interface
Alguém consegue agir	6	**8**	Plano de 30 dias com amostra a rotular, critério para ligar e para desligar

Veredito: pronta com ressalvas

Só três ressalvas mudariam a avaliação; com as três feitas, o veredito passa a **pronta para enviar**.

1. **Preencher os campos em branco**, principalmente "o que eu adicionei". O G4 avalia o Process Log como obrigatório, e essa seção é a voz do candidato, não a da IA. Sem ela, a entrega fica incompleta.
2. **Corrigir as três frases do README**: "volume" em vez de "acerta"; "no Dataset 2" em vez de "em qualquer cenário"; "histórico de filas, auditado por amostra" em vez de "já são os rótulos". São as únicas promessas acima do medido, e estão na seção que o diretor lê.
3. **Alinhar os números antigos** do Process Log e do protótipo (20 → 25 decisões, "espera do cliente", R$ 23 mil, 64%, "validada", "tempo de espera"). Um avaliador que cruza documentos vai notar.